

Analfabetismo: identificando fatores e prioridades para batimento de metas

Fiap Pós - AI Scientist
2026
Fase 3

Grupo:
Ricardo Sallin - RM 372803
Bruno Saralha - RM 370184
Fernando Medeiros - RM 370318
Rodrigo Alves - RM 372519

Qual problema de negócio está sendo resolvido?

- Pesquisa Alfabetiza Brasil (2023)
- Criança alfabetizada = 743 pontos no Saeb na prova de Língua Portuguesa (LP)
 - Meta: 100% de crianças Alfabetizadas até 2030.
- Dados socioeconômicos ajudam a prever:
 - Municípios problemáticos para atingimento de meta
 - Municípios com melhores resultados obtidos com os recursos atuais

ID Aluno (anonimizado)	Nota Saeb	Status
87651234	820	Alfabetizado
29384756	797	Alfabetizado
32165497	784	Alfabetizado
98237645	779	Alfabetizado
41028394	760	Alfabetizado
65498765	750	Alfabetizado
76543298	732	↓ Não-Alfabetizado
18278364	702	↓ Não-Alfabetizado

Qual problema de negócio está sendo resolvido?

Hipóteses de trabalho:

- **Renda média:** em municípios mais ricos as crianças performam melhor?
- **Alfabetização dos pais:** ambientes com mais letramento dos adultos influenciam positivamente?
- **Investimento em educação:** municípios que investem mais obtêm mais "retorno" em literácia e, indiretamente, em produtividade e no próprio PIB?
- **Dificuldade de acesso:** municípios com poucas escolas proporcionalmente à população, ou por área, alfabetizam menos?
- **Região Metropolitana:** será que municípios próximos à capital alfabetizam menos?

Pipeline de Dados

- INEP - alfabetização infantil: basedosdados.org
- Renda média por município: [Kaggle PNAD](#) + [Lat-Long](#) municipal para inferência
- Repasse Fundeb por município: [MeuFundeb](#),
- Complementação Vaaf-Vaat/Vaar: [Diário Oficial](#) e
- Despesas Educação: [ConectaProfs](#)
- Área/pop por município: [IBGE](#)
- Alfabetização adultos (20-64) e idosos (65+): [Censo](#)

Ajustes manuais nos dados Gov: nomes de municípios, agrupamentos etc

Importação de CSV's no BigQuery (Camada Bronze) + SQL (camadas Silver/Gold)

Tabelas Gold alimentando modelos ML

Estrutura das tabelas

Bronze:

area_pop: dados básicos por município (nome, UF, área km2 e população)

mun_renda_inferida: renda média por município de ~200 maiores cidades, e inferência para os demais ~5370

receitas_despesas: valor repassado pelo Fundeb por município, e complementações VAAF, VAAT e VAAR

dist_km_capital: latitude, longitude, e distância até a capital correspondente em km

alfabetizacao_infantil: qtd alunos, % alfabetizados, e qtd escolas, por município, por ano (23-24)

alfabetizacao_adultos_idosos: qtd pessoas e % alfabetizado por município, faixas 20-64 anos e 65+ anos

_meta: metas de alfabetização '25 por município obtida no módulo anterior do curso

Silver:

_municipios: tabela temporária dos municípios: nome, uf, lat/long, capital, população, área, densidade, renda média, receitas e despesas

_alfabetizacao: tabela temporária juntando alfab infantil, adulto e idoso e dados Censo escolar (qtd escolas, alunos etc)

_silverfinal: tabela reunindo todas as variáveis que irão para algum modelo ML

_silverfinal_semnulos: tabela extra, apenas imputando zeros para os nulos da **_silverfinal**

Gold:


_reg_arv_treino: tabela de treino para os modelos de Regressão Logística e Random Forest. Contém apenas 2023

_reg_arv_teste: tabela de teste para os modelos de Regressão Logística e Random Forest. Contém apenas 2024

_kmeans_treino: tabela de treino para o modelo de K-means. Contém apenas 2023

Clusterização de Municípios com K-means

- Variáveis usadas: população, densidade, renda, alfabetização (adulto e idoso apenas: infantil (target) não entrou), distância à capital e se é capital
- Grupos identificados:
 - **Capitais:** grandes e densas, com alta renda e muito alfabetizadas (grupo 5)
 - **Regiões Metropolitanas:** parecidas com as Capitais, mas menos ricas e alfabetizadas (grupo 4)
 - **Interior/Ricas:** cidades menores, com renda menor. Começam os desafios educacionais (grupos 3 e 2)
 - **Interior/Pobres:** baixa renda per capita dificulta acesso à escola (grupos 0 e 1)



Ranqueamento de fatores com Random Forest

Variáveis preditoras utilizadas: distância à capital, área, densidade, renda, repasse Fundeb+Compl, qtd alunos/escolas, alfabetização adultos

- Fatores estruturais: Alfab adultos e Renda
- Principal fator acionável: **Receita Fundeb**
- Complementações VAA têm peso menor

```
Dimensão do dataset: (4871, 14)
Variáveis preditoras utilizadas: ['dist_capital', 'area_km2', 'd

--- Desempenho do Random Forest (holdout 20%) ---
MAE (erro médio absoluto): 8.195 pontos percentuais
R² (holdout): 0.349
R² (média CV 5-fold): 0.271 (+/- 0.066)

--- Ranking de importância das variáveis (Random Forest) ---
      variavel  importancia
alfab_adulto   0.187883
renda_media    0.164224
dist_capital   0.083247
receita_fundeb 0.082564
dens_pop       0.079159
area_km2       0.079070
compl_vaaf     0.074426
compl_vaat     0.068345
qtd_escolas_100k 0.067898
qtd_alunos     0.066978
compl_vaar     0.046206
```

Probabilidade Ating. Meta com Regressão Logística

Variáveis preditoras utilizadas:

alfabetização adultos, renda,
escolas/100k, Compl VAAF e VAAT

- Top municípios mais e menos propensos a atingir as metas de Alfabetização '25

```
--- Coeficientes da Regressão Logística (na
      variavel      coeficiente      odds_ratio
receita_fundeb      -3.750433      0.023508
qtd_alunos          1.165950      3.208971
desp_liquidada      1.017441      2.766108
  Compl_Total        0.466665      1.594667
  alfab_idoso        0.454405      1.575237
  area_km2          -0.269010      0.764136
  renda_media        0.222063      1.248650
  alfab_adulto       -0.205879      0.813932
  dens_pop          -0.202604      0.816601
  dist_capital       0.113571      1.120271
qtd_escolas_100k    0.068930      1.071361
  financ_por_aluno   -0.019256      0.980928
```

Relatório de classificação completo:				
	precision	recall	f1-score	support
Nao_bate_meta	0.61	0.57	0.59	3130
Bate_meta	0.48	0.52	0.50	2387
accuracy			0.55	5517
macro avg	0.55	0.55	0.54	5517
weighted avg	0.55	0.55	0.55	5517

```
--- Top 10 municípios com maior probabilidade de bater a meta infantil (df_teste) ---
      nome      TARGET_alfab_infantil      meta_alfabetizacao_2025      prob_bate_meta_infantil
Caucaia          68.47          71.16          0.99
Imperatriz        54.63          56.42          0.93
Canaã dos Carajás  65.34          67.89          0.93
Sobral           98.57          80.00          0.89
São Bernardo do Campo  54.30          63.55          0.89
Crateús          97.18          80.00          0.82
Aracati          91.16          80.00          0.82
Belém            52.24          58.55          0.82
Quixeramobim     98.74          80.00          0.81
Salvador das Missões  61.11          80.00          0.80
```

```
--- Top 10 municípios com MENOR probabilidade de bater a meta infantil (df_teste) ---
      nome      TARGET_alfab_infantil      meta_alfabetizacao_2025      prob_bate_meta_infantil
Duque de Caxias    45.66          57.80          0.0
Recife            54.63          68.08          0.0
Cuiabá            46.92          62.45          0.0
Porto Alegre       28.30          NaN          0.0
Belo Horizonte    70.53          64.91          0.0
Campo Grande      51.69          53.84          0.0
Curitiba         66.18          73.41          0.0
Rio de Janeiro    64.29          63.97          0.0
Brasília          59.43          NaN          0.0
São Paulo         56.59          51.06          0.0
```


Fundeb: impacto negativo na Regressão Logística

- O coeficiente negativo do Fundeb na Regressão Logística nos chamou atenção e decidimos voltar à EDA para averiguar
- Começamos com uma correlação direta entre Financiamento Fundeb (com ou sem as Complementações) e o Atingimento Meta (diferença entre a meta do município e a Alfabetização realizada)
- Essas variáveis têm correlação muito baixa, e ainda negativa (-0,14)
- Casos extremos nos 4 quadrantes:

```
--- Coeficientes da Regressão Logística (ra
```


variavel	coeficiente	odds_ratio
receita_fundeb	-3.750433	0.023508
qtd_alunos	1.165950	3.208971
desp_liquida	1.017441	2.766108

Cidade (pop)	Fundeb /aluno '23	Meta '23 %	Alfab %	Ating. (pp)
● Coruripe/AL (50k)	111k	80%	94%	+14
● Januária/MG (65k)	60k	35%	40%	+5
● Serrinha/BA (80k)	185k	41%	26%	-15
● Maceió/AL (957k)	57k	52%	39%	-13



Fundeb: impacto negativo na Regressão Logística

- Grande variabilidade em ambas variáveis no tempo ('24 vs '23)
- Provavelmente resultado de variáveis políticas, emendas, “orçamento secreto” etc.
- Demais variáveis explicativas do modelo (geográficas, sociais, macroeconômicas): todas fixas ou variando em décadas, não anos
- Dado que usamos 2023 como treino e 2024 como teste, essa variabilidade explica o papel de destaque dessa variável nos modelos



Cidade (pop)	Var. Fundeb	Ating. Meta '23	Ating. Meta '24	Var Ating.
 Cel. Fabriciano/MG (104k)	+21%	-10pp	+6pp	+16pp
 São Borja/RS (59k)	+23%	-6pp	-23pp	-17pp
 Breves/PA (107k)	-19%	-11pp	+1pp	+12pp
 Iranduba/AL (61k)	-18%	-11pp	-19pp	-8pp

Conclusões

- **Financiamento Fundeb** foi a variável de maior impacto no modelo, mas com coeficiente negativo, associado a municípios com maior financiamento e menor analfabetismo.
- Retomamos a EDA para investigar o resultado, comparando financiamento Fundeb e atingimento das metas entre 2023 (treino) e 2024 (teste).
- **Alta variabilidade nas duas variáveis**, resultando em uma correlação muito baixa entre financiamento e atingimento da meta.
- Concluimos que são necessárias mais variáveis, detalhando como o Fundeb é aplicado, e fatores socioeconômicos como infraestrutura, ensino, criminalidade e insegurança alimentar.

Obrigado